

Corporación Universitaria Iberoamericana

Facultad de Ingeniería

Ingeniería de Ciencias de Datos.

Inteligencia Artificial.

Integrantes del equipo:

Carlos David Alvarez Ojeda.

Manuel Galindo Peña.

Docente:

Joaquin Sánchez.

Bogotá.

Fecha: 07/06/2026.

1. Introducción

El presente documento tiene como propósito describir detalladamente el conjunto de datos (*dataset*) estructurado para la fase de aprendizaje no supervisado del Sistema Inteligente de Transporte. Mientras que en la actividad anterior se utilizó una representación de grafo para la búsqueda de rutas (algoritmo BFS), en esta etapa se integraron variables operativas para categorizar las estaciones mediante el algoritmo de agrupamiento K-Means, con el fin de descubrir perfiles de operatividad ocultos en la red.

2. Enlaces del Proyecto

- **Repositorio Git:** https://github.com/CARLITOSSS24/Proyecto_IA_NoSupervisado-.git

3. Origen de los Datos

Debido a que la base de conocimiento original del proyecto solo definía nodos (estaciones) y aristas (conexiones lógicas), se procedió a desarrollar un *dataset* sintético. Este conjunto de datos respeta la topología de la red original y añade variables numéricas coherentes con el comportamiento real de un sistema de transporte masivo en horas pico.

4. Diccionario de Datos

El archivo fuente utilizado por el modelo de Python (`dataset_estaciones.csv`) consta de las siguientes 6 columnas:

1. **Estacion (Categorica):** Nombre identificador del nodo en la red de transporte (Ej. Portal Norte, Heroes, Aeropuerto).
2. **Pasajeros_Dia (Numérica - Entero):** Volumen promedio de usuarios que ingresan y transitan diariamente por la estación.
3. **Tiempo_Espera_Min (Numérica - Flotante):** Tiempo promedio, en minutos, que un usuario debe esperar en la plataforma para abordar una ruta.
4. **Conexiones (Numérica - Entero):** Cantidad de rutas o enlaces directos hacia otras estaciones. Esta variable se extrajo exactamente del diccionario de Python de la actividad de búsqueda BFS.
5. **Buses_Hora (Numérica - Entero):** Frecuencia o cantidad de vehículos articulados que transitan por la estación durante una hora de alta demanda.
6. **Incidentes_Mes (Numérica - Entero):** Cantidad de reportes de fallas técnicas, bloqueos en puertas o retrasos operativos registrados en el último mes.

5. Justificación de la Muestra (Análisis de Nodos Clave)

Los valores asignados en el *dataset* fueron diseñados para que el modelo K-Means pudiera diferenciar tres escenarios operativos claros, evaluando la red de la siguiente manera:

- **Nodos Troncales (Ej. Heroes, Portal Norte):** Al poseer múltiples conexiones (2 a 3 enlaces), se les asignó un alto volumen de pasajeros (más de 50,000) y una mayor tasa de incidentes, simulando cuellos de botella reales en el sistema.
- **Nodos de Flujo Moderado/Destino (Ej. Museo, Calle 72):** Estaciones con 1 o 2 conexiones que funcionan como puntos de destino final, presentando flujos de pasajeros moderados y tiempos de espera bajos.

- **Nodos Aislados (Ej. Aeropuerto):** Para validar el comportamiento de anomalías, se mantuvo la estación Aeropuerto con 0 conexiones (tal cual se descubrió en la prueba BFS anterior), agregando un flujo de pasajeros casi nulo (500) y tiempos de espera críticos (15 min). Esto garantiza que el algoritmo de inteligencia artificial lo aísle en un clúster independiente.